

RF30 — Gestão de Dados Mestres (Master Data Management - MDM)

Programa: FIC DEV IA — Programador de Sistemas com IA
Módulo: Fundamentos de Dados para IA
Projeto: Pipeline Governado, Escalável e Seguro de Conteúdos Educacionais

1. Visão Geral da Entidade Mestre

No contexto do ecossistema educacional do projeto, a entidade central escolhida para a disciplina de **Dados Mestres (MDM)** é o **Conteúdo Educacional** ([Conteúdo](#)).

- Esta entidade é referenciada transversalmente por:
- * Catálogo de cursos e trilhas formativas;
 - * Eventos de interação e consumo dos alunos;
 - * Sessões de avaliação e comentários didáticos;
 - * Modelos preditivos e motores de recomendação;
 - * Painéis executivos de retenção escolar na Camada Gold.

2. Definição da Chave de Negócio e Atributos Essenciais

Parâmetro MDM	Especificação Técnica e Negocial
Entidade Mestre	Conteúdo Educacional (Course / Educational Asset)
Chave de Negócio Natural	Normalização de (titulo_slug + autor_id + tipo)
Identificador Mestre (Golden ID)	conteudo_id (Chave substituta unificada gerada em si
Fonte de Referência Primária	Sistema de Catálogo Acadêmico (dados/entrada/catalog
Atributos Essenciais	• titulo: Título oficial do conteúdo • tipo: Formato instrucional (video, curso, podcast, • categoria: Área temática do conhecimento • nivel: Complexidade pedagógica (basico, intermedia • data_publicacao: Data canônica de disponibilização • autor: Docente / Autor responsável

3. Regras de Correspondência, Deduplicação e Sobrevivência (Survivorship)

Para resolver inconsistências decorrentes da ingestão de múltiplas fontes ou cadastros duplicados, o pipeline aplica as seguintes regras determinísticas na transição Bronze $\rightarrow$ Silver:

3.1. Regra de Correspondência (Matching)

1. **Correspondência Exata:** Se `conteudo_id` for idêntico.
2. **Correspondência Fuzzy / Fonética:** Similaridade textual $\geq 95\%$ no título padronizado (caixa baixa, remoção de acentos e caracteres especiais) associada ao mesmo autor e tipo de mídia.

3.2. Regra de Sobrevivência (Survivorship Rule)

Quando dois ou mais registros representam a mesma entidade de negócio com divergência de valores:

- * **Título e Descrição:** Prevalece o registro com maior completude de caracteres (não nulo mais detalhado).
- * **Categoria e Nível:** Prevalece a classificação mais recente (`data_publicacao` mais recente) originada do sistema acadêmico mestre.
- * **Carga Horária:** Prevalece o valor numérico positivo não nulo verificado.
- * **Chave Mestre Atribuída:** O menor `conteudo_id` original é preservado como *Golden Record*, e as ocorrências secundárias são unificadas na tabela de correspondência (*Cross-Reference / XRef*).

4. Demonstração Prática de Resolução de Conflito

Considere dois registros conflitantes recebidos na ingestão:

REGISTRO A (Fonte: CSV Catálogo Antigo):

```
{
  "conteudo_id": 105,
  "titulo": "Pipelines e Transformações com Apache Hop",
  "tipo": "video",
  "categoria": "Engenharia de Dados",
  "nivel": "basico",
  "data_publicacao": "2025-01-10",
  "autor": "Carlos Eduardo"
}
```

REGISTRO B (Fonte: Cadastro Recente de Plataforma LMS):

```
{
  "conteudo_id": 892,
  "titulo": "Pipelines e Transformacoes com Apache Hop - Edição 2026",
  "tipo": "video",
  "categoria": "Data Engineering",
  "nivel": "intermediario",
  "data_publicacao": "2026-02-15",
  "autor": "Prof. Carlos Eduardo Silveira"
}
```

Aplicação das Regras MDM no Pipeline:

1. **Correspondência:** O motor detecta similaridade de 92% no título e equivalência do autor (`Carlos Eduardo` $\subset$ `Carlos Eduardo Silveira`).
2. **Sobrevivência:**
3. **Título Canônico:** `Pipelines e Transformações com Apache Hop – Edição 2026` (mais descritivo e atualizado).
4. **Categoria Padronizada:** `Engenharia de Dados` (mapeada a partir da taxonomia do glossário da Silver).
5. **Nível:** `intermediario` (registro mais recente de 2026).
6. **Golden ID Definido:** `conteudo_id = 105` .
7. **Registro Golden Consolidado na Camada Silver (`silver.catalogo`):**

```
json { "conteudo_id": 105, "titulo": "Pipelines e Transformações com Apache Hop – Edição 2026", "tipo": "video", "categoria": "Engenharia de Dados", "nivel": "intermediario", "data_publicacao": "2026-02-15", "autor": "Prof. Carlos Eduardo Silveira", "origem_principal": "golden_record_mdm" }
```
8. **Tabela de De-Para (XRef):** Qualquer interação ou comentário associado originalmente ao `conteudo_id = 892` é automaticamente remapeado para `105` , impedindo fragmentação métrica na Camada Gold.