

Documentação de Linhagem de Dados (Data Lineage)

Programa: FIC DEV IA — Programador de Sistemas com IA

Módulo: Fundamentos de Dados para IA

Projeto: Pipeline Governado, Escalável e Seguro de Conteúdos Educacionais

Versão: 1.0 — 2026

1. Apresentação e Escopo da Linhagem

A presente documentação descreve formalmente o fluxo unidirecional e auditável de dados da plataforma educacional, cobrindo o percurso completo desde os arquivos de origem até a camada final de consumo e tomada de decisão estratégica no Apache Superset.

O objetivo desta especificação é garantir **confiabilidade institucional**, **reprodutibilidade técnica** e atendimento às exigências regulatórias de **auditoria de dados** e **governança**.

2. Diagrama de Linhagem Ponta a Ponta

```
graph LR
    subgraph S1_Ingestao [Camada de Ingestão]
        F_CAT["catalogo.csv"]
        F_INT["interacoes.json"]
        F_COM["comentarios.json"]
        F_REC["recomendacoes (D1)"]
    end

    subgraph S2_Bronze [Camada Bronze: Imutável e Auditável]
        B_CAT["bronze.catalogo"]
        B_INT["bronze.interacoes"]
        B_COM["bronze.comentarios"]
        B_REC["bronze.recomendacoes"]
    end

    subgraph S3_Silver [Camada Silver: Conforme e Quarentenada]
        S_CAT["silver.catalogo"]
        S_INT["silver.interacoes"]
        S_COM["silver.comentarios"]
        S_REC["silver.recomendacoes"]
        Q_ERR["quarentena.*"]
    end

    subgraph S4_Distribuido [Camada Big Data: Apache Beam]
        PQ_SILVER["Parquet Silver Particionado (ano_mes)"]
        BEAM_JOB["Apache Beam: Agrupamento por Conteúdo"]
        PQ_GOLD["Parquet Agregado Staging"]
    end

    subgraph S5_Gold [Camada Gold: Analítica e Otimizada]
        G_ENG["gold.engajamento_conteudo"]
        G_MEN["gold.engajamento_conteudo_mensal"]
        V_CAT["gold.vw_resumo_categoria"]
        V_ATN["gold.vw_conteudos_atencao"]
    end
```

```
end

subgraph S6_SQLLab [Camada Semântica: SQL Lab]
  DS_ENG["ds_virtual_desempenho_engajamento conteudos"]
  DS_TEM["ds_virtual_evolucao_temporal_eficiencia"]
end

subgraph S7_Dashboard [Camada Executiva: Apache Superset]
  DASH["Dashboard Executivo de Engajamento"]
  KPI_CONC["KPI: Taxa de Conclusão Global"]
  KPI_RISCO["KPI: Cursos em Risco de Evasão"]
  ALERT_EVASAO["Alerta Automatizado de Evasão"]
end

%% Conexões
F_CAT →|Hop: bronze_catalogo.hpl| B_CAT
F_INT →|Hop: bronze_interacoes.hpl| B_INT
F_COM →|Hop: bronze_comentarios.hpl| B_COM
F_REC →|Ingestão de Continuidade| B_REC

B_CAT →|Hop: silver_catalogo.hpl| S_CAT
B_CAT -.->|Inconsistências| Q_ERR
B_INT →|Hop: silver_interacoes.hpl| S_INT
B_INT -.->|Inconsistências| Q_ERR
B_COM →|Hop: silver_comentarios.hpl| S_COM
B_REC →|Padronização| S_REC

S_INT →|exportar_parquet.py| PQ_SILVER
PQ_SILVER →|pipeline_beam.py| BEAM_JOB
BEAM_JOB → PQ_GOLD
PQ_GOLD →|carregar_gold.py + JOIN silver.catalogo| G_ENG
S_INT →|Agregação Mensal SQL| G_MEN

G_ENG → V_CAT
G_ENG → V_ATN
G_ENG → DS_ENG
G_MEN → DS_TEM

DS_ENG → DASH
DS_TEM → DASH
V_CAT → DASH
V_ATN → KPI_RISCO
V_ATN → ALERT_EVASAO
DS_ENG → KPI_CONC
```

3. Matriz de Transformações e Contratos de Dados

Origem (De)	Destino (Para)	Mecanismo	Transformação Aplicada	Regra de Negócio / Qualidade
catalogo.csv	bronze.catalogo	Apache Hop	Cópia literal auditada	Inserção de execucao_id e carimbo de data/hora sem alterar texto original.

Origem (De)	Destino (Para)	Mecanismo	Transformação Aplicada	Regra de Negócio / Qualidade
<code>bronze.catalogo</code>	<code>silver.catalogo</code>	Apache Hop	Parsing de datas e limpeza	Conversão de tipos (<code>FLOAT8</code> , <code>DATE</code>), remoção de espaços e quarentena de IDs nulos.
<code>interacoes.json</code>	<code>bronze.interacoes</code>	Apache Hop	Parsing JSONB	Preservação do JSON estruturado na íntegra com metadados de ingestão.
<code>bronze.interacoes</code>	<code>silver.interacoes</code>	Apache Hop	Desaninhamento e tipagem	Extração de atributos do JSONB para colunas relacionais com validação de chaves.
<code>silver.interacoes</code>	Parquet Particionado	Python / PyArrow	Particionamento em disco	Criação da partição <code>ano_mes = YYYY-MM</code> baseada no timestamp da interação.
Parquet Silver	Parquet Gold Staging	Apache Beam	Agregação distribuída	<code>CombinePerKey</code> somando total de interações, segundos e conclusões por <code>conteudo_id</code> .
Parquet Gold	<code>gold.engajamento_conteudo</code>	Python / psycpg	Carga relacional e enriquecimento	<code>LEFT JOIN</code> com <code>silver.catalogo</code> para recuperar título, nível e categoria.
<code>gold.engajamento_conteudo</code>	<code>ds_virtual_desempenho</code>	SQL Lab	Visualização virtual	<code>CASE WHEN</code> calculando status de retenção e taxa efetiva de conclusão.
<code>ds_virtual_desempenho</code>	Dashboard Superset	Apache Superset	Renderização analítica	Aplicação de filtros cruzados e formatação de métricas executivas.

4. Garantia de Rastreabilidade e Reprodutibilidade

Qualquer métrica exibida na diretoria (por exemplo: um gráfico de evasão no Superset) pode ter sua linhagem auditada em minutos seguindo a chave primária `conteudo_id`:

1. No Superset: identifica-se a consulta base do gráfico (`ds_virtual_desempenho_engajamento conteudos`);
2. No PostgreSQL: consulta-se a linha correspondente em `gold.engajamento_conteudo` ;
3. No Lakehouse/Parquet: valida-se a soma consolidada na partição gerada pelo Apache Beam;
4. Na camada Silver: executa-se a contagem de linhas em `silver.interacoes` para aquele ID;
5. Na camada Bronze: verifica-se a integridade do JSON original arquivado na ingestão inicial.

Essa arquitetura elimina divergências entre relatórios e confere **segurança operacional e jurídica** à tomada de decisões da plataforma.